
# HSE Data Science Hack




Галимзянова Дарья, НИУ ВШЭ Богданова Анна, НИУ ВШЭ Лебедева Анна, НИУ ВШЭ

#### Баланс классов



#### Баланс классов



#### **Mean word counts**

In all categories: 5.97


Positive: 6.24

Negative: 5.86


general word cloud on lemmatized data:



positive messages word cloud:



negative messages word cloud:



## Использование Yandex Datasphere

#### Итоги:

- Создали проект
- Подключили s3 (сохраняли чекпоинты модели)
- Подключили git

## Проблемы:

- kernel самопроизвольно перезапускается, значения всех переменных пропадают
- Проблемы с зависимостями

#### Препроцессинг данных


- Удаление пунктуации
- Лемматизация через pymorphy2
- Векторизация

#### Бейзлайн

Комбинация	RandomForestClassifier
TfidfVectorizer	0.9289
CountVectorizer	0.9293
TfidfVectorizer w/lemm	0.9314
CountVectorizer w/lemm	0.9332

# Сентимент

Модель	ROC-AUC score		
RandomForestClassifier	0.9332		
Catboost	0.9304		
Catboost + Optuna	0.9279		
Rubert finetuned (46 эпох)	~ 0.55		




● ● Intro Hook	Explore Explain	Apply Share	Evaluate Expand
----------------	-----------------	-------------	-----------------

		precision	recall	f1-score	support	
	0 1 2	0.87 0.65 0.89	0.90 0.49 0.94	0.89 0.56 0.91	626 291 1020	
accurad macro av weighted av	٧ġ	0.81 0.85	0.78 0.86	0.86 0.79 0.85	1937 1937 1937	

## RuBERT fine-tuning

- DeepPavlov/rubert-base-cased
- Замораживание весов предобученной модели, дообучение классифицирующей головы (два линейных слоя), использование StepLR
- Количество эпох: 45



# Категории

- Preprocessing:
  - токенизация,
  - лемматизация,
  - удаление стоп-слов,
  - TfldfVectorizer,
  - MultiLabelBinarizer

**ROC-AUC: 0.825** 

RandomForestClassifier(n\_estimators=300)